

LSTM을 이용한 표면 근전도 분석을 통한 서로 다른 손가락 움직임 분류 정확도 향상

신재영¹ · 김성욱² · 이운성² · 이형탁² · 황한정^{2*}

¹원광대학교 전자공학과

²금오공과대학교 메디컬IT융합공학과

Improvement of Classification Accuracy of Different Finger Movements Using Surface Electromyography Based on Long Short-Term Memory

Jaeyoung Shin¹, Seong-Uk Kim², Yun-Sung Lee², Hyung-Tak Lee² and Han-Jeong Hwang^{2*}

¹Department of Electrical Engineering, Wonkwang University

²Department of Medical IT Convergence Engineering, Kumoh National Institute of Technology

(Manuscript received 8 October 2019 ; revised 5 December 2019 ; accepted 9 December 2019)

Abstract: Forearm electromyography (EMG) generated by wrist movements has been widely used to develop an electrical prosthetic hand, but EMG generated by finger movements has been rarely used even though 20% of amputees lose fingers. The goal of this study is to improve the classification performance of different finger movements using a deep learning algorithm, and thereby contributing to the development of a high-performance finger-based prosthetic hand. Ten participants took part in this study, and they performed seven different finger movements forty times each (thumb, index, middle, ring, little, fist and rest) during which EMG was measured from the back of the right hand using four bipolar electrodes. We extracted mean absolute value (MAV), root mean square (RMS), and mean (MEAN) from the measured EMGs for each trial as features, and a 5x5-fold cross-validation was performed to estimate the classification performance of seven different finger movements. A long short-term memory (LSTM) model was used as a classifier, and linear discriminant analysis (LDA) that is a widely used classifier in previous studies was also used for comparison. The best performance of the LSTM model (sensitivity: $91.46 \pm 6.72\%$; specificity: $91.27 \pm 4.18\%$; accuracy: $91.26 \pm 4.09\%$) significantly outperformed that of LDA (sensitivity: $84.55 \pm 9.61\%$; specificity: $84.02 \pm 6.00\%$; accuracy: $84.00 \pm 5.87\%$). Our result demonstrates the feasibility of a deep learning algorithm (LSTM) to improve the performance of classifying different finger movements using EMG.

Key words: Electromyography (EMG), Finger movement classification, Deep learning, Recurrent neural network (RNN), Long short-term memory (LSTM)

I. 서 론

근전도(electromyography: EMG) 신호는 근육 움직임에 의해 발생하는 전기적인 신호이며, 신경근(neuromuscular)에 대한 많은 정보를 담고 있기 때문에 근육 질환 진단 및 재

활 분야에 폭 넓게 활용이 되고 있다. 특히, 팔이나 손의 일부를 잃어버린 사람들의 해당 기능을 복원할 수 있도록 도와주는 전자 의수 개발을 위한 입력 신호로 근전도 신호가 널리 활용되고 있다[1-3].

대부분의 근전도 기반 전자 의수 개발 관련 선행 연구에서는 손목의 움직임에 의해 유도되는 팔뚝의 근전도 신호를 활용하였으며, 해당 움직임을 패턴인식 기법으로 분류 및 역추정 하여 전자 의수를 제어하는 명령어를 생성하게 된다. 팔뚝에서 측정되는 근전도 신호를 가장 많이 사용하는 이유는 매년 발생하는 상지 절단 환자(upper-limb amputee) 중 약

Corresponding Author : Han-Jeong Hwang
350-27, Gumi-daero, Gumi-si, Gyeongsangbuk-do, Republic of Korea
Tel : +82-54-478-7783
E-mail : h2j@kumoh.ac.kr
이 연구는 금오공과대학교학술연구비에 의하여 지원된 논문임

80%가 팔꿈치와 손목 사이(팔뚝 일부)의 절단이기 때문이다(미국 기준[4]). 하지만, 상지 절단 환자 중 약 20%가 손가락의 일부를 손실함에도 불구하고, 이들을 위한 전자 의수 연구는 상대적으로 미비한 상황이다[4]. 또한, 손가락 움직임을 활용할 경우 정상인을 위한 인간-컴퓨터 상호작용(Human-Computer Interaction: HCI) 응용 개발에도 적용이 가능하므로 관련 연구 개발이 필요하다.

서로 다른 손 움직임에 의해 유도되는 근전도 신호를 자동으로 분류하여 전자 의수를 제어하는 명령어를 생성하기 위해 패턴 인식 기반 알고리즘이 많이 활용되고 있다. 그 동안 분류 정확도 향상을 위해 많은 패턴인식 알고리즘들이 제안되었으며, 근전도 신호의 진폭(amplitude), 주파수(frequency), 발생 기간(duration) 등의 정보를 담고 있는 특징을 선형 분류기(Linear Discriminant Analysis: 이하 LDA)로 분류할 경우 우수한 분류 정확도를 얻을 수 있다는 것이 밝혀졌다[5-7]. 현재까지 개발된 패턴인식 알고리즘을 활용할 경우 상지 일부 절단 환자의 경우 5-10개 내외의 서로 다른 손동작을 약 80-90%의 정확도로 분류할 수 있다는 것이 보고되었다[8-11].

본 연구에서는 팔뚝 근전도를 사용하는 연구 대비 상대적으로 연구 수행이 미비한 손가락 움직임에 의해 유도되는 근전도 신호를 활용하여 서로 다른 손가락 움직임을 높은 정확도로 분류하는 것을 목표로 하고 있으며, 궁극적으로 손가락 일부를 잃어버린 환자들을 위한 고성능 손가락 기반 전자 의수를 개발하는 것에 기여하고자 한다. 본 연구에는 10명의 피험자가 실험에 참가하여 서로 다른 7가지 손가락 움직임을 반복 수행하였으며, 이 때 손등에서 손가락 움직임에 의해 유도되는 근전도 신호를 측정하였다. 측정한 근전도 신호로부터 선행 연구에서 가장 많이 활용되는 특징을 추출한 후, 순환 신경망(Recurrent Neural Networks: RNN)의 일종인 Long Short-Term Memory(LSTM) 딥러닝 알고리즘을 이용하여 서로 다른 손가락 움직임의 분류 정확도를 산출하였다. 또한, 관련 선행 연구에서 많이 사용 해온 LDA를 이용하여 산출한 분류 정확도와 비교를 통해 딥러닝(LSTM) 알고리즘의 유용성을 검증하였다.

II. 연구 방법

1. 실험 대상

본 실험에는 20대 피험자 10명이 참가하였다(6명 남자, 4명 여자, 25.1 ± 1.52 세). 모든 피험자의 주사용 손은 오른손이었으며, 실험 결과에 영향을 줄 정도의 손과 손가락 질환을 앓은 적이 없었다. 모든 피험자에게 실험 과정에 대해 최대한 상세히 설명하였으며, 실험 전 실험 동의서에 서명을 받았다. 10명의 피험자 중 3명(S1, S2, S3)의 경우 과거 유사한 실험에 참가한 경험이 있었으며, 나머지 7명의 피험자는 처음

으로 근전도 측정 실험에 참가하였다. 본 연구의 실험 프로토콜은 금오공과대학교 연구윤리위원회의 승인을 받았다(No. 6250).

2. 근전도 데이터 수집

근전도 신호는 아두이노 메가(Arduino Mega) 2560 보드 기반 생체 신호 측정 모듈을 이용하여 측정하였다. 근전도 신호 샘플링율은 근전도 신호를 측정하는 아두이노 보드와 데이터 측정에 사용한 컴퓨터 사이의 COM포트 통신의 영향으로 조금씩 변화하였지만, 측정과 분석에 영향을 줄만큼 그 편차가 크지는 않았다(333.9 ± 1.79 Hz). 손가락 움직임과 관련된 근전도 신호를 측정하기 위해 주사용 손의 손등에 그림 1과 같이 4개의 쌍극 전극(bipolar electrode)을 부착하였으며, 각 쌍극 전극에 대응하는 레퍼런스 전극들은 손목 위쪽에 부착하였다. 근전도 신호를 측정하는 동안 팔 움직임에 의한 신체적인 잡음 유입을 방지하기 위해 피험자는 의자 팔걸이에 손을 고정하였다. 자연스러운 손가락 움직임을 유도하기 위해 손목을 고정하지는 않았지만 잡음 유입을 방지하기 위해 불필요한 손목의 움직임을 자제하도록 요청하였다.

3. 실험 패러다임

개별 피험자는 그림 2에 도시한 것처럼 7개의 서로 다른 손가락 움직임 동작을 수행하였다: 1-5) 엄지, 검지, 중지, 약지, 소지 구부리기, 6) 주먹 쥐기, 7) 편안한 상태 유지. 모든 손가락 움직임 동작은 수행 후 손가락을 원 위치 하는 것을 포함한다. 개별 시행은 피험자가 7개의 손가락 움직임 중 특정 하나의 동작을 지시하는 그림에 따라 2초 안에 수행하였으며, 다음 시행을 위해 개별 시행 사이에 3초의 휴식기를 제공하였다. 개별 손가락 움직임에 대한 지시는 무작위로 제시되었으며, 각 손가락 움직임 별로 총 40회의 시행을 수행하였다(피험자별 7개 손가락 움직임 \times 40회 = 280 시행).




그림 1. 근전도 신호 측정에 사용한 4개의 쌍극 전극과 레퍼런스 전극 위치

Fig. 1. Positions of four bipolar electrodes and their corresponding reference electrodes

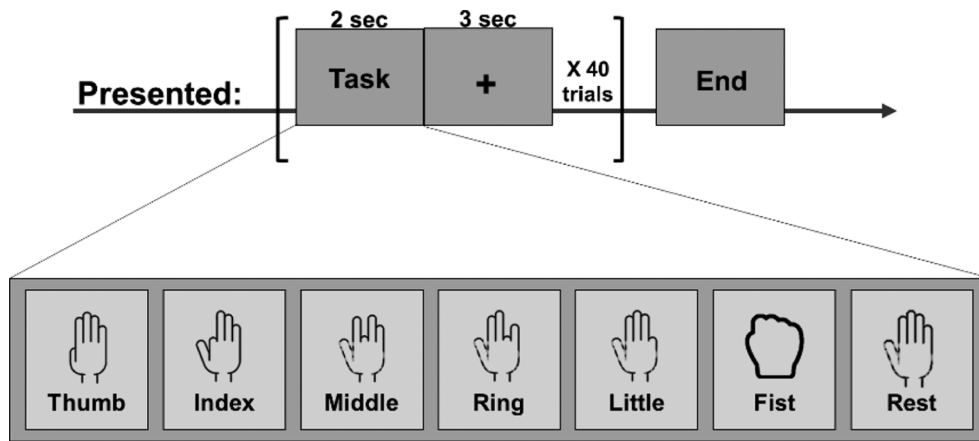


그림 2. 실험 패러다임. 7개의 손가락 움직임 중 하나에 대응하는 그림이 제시되고 피험자는 2초 동안 해당 손가락 움직임 과제를 수행. 피험자가 수행해야 하는 손가락 움직임을 나타내는 그림은 무작위로 제시되었으며, 개별 시행 사이에는 3초의 휴식기가 제공. 각 손가락 움직임 별로 총 40회의 시행을 수행함

Fig. 2. Experimental paradigm. The subject carries out a finger movement for 2 s after a picture indicating which finger a subject should move is presented. A picture indicating which finger a subject should move is randomly presented, and a 3-s break is give between trials. Each finger movement is performed 40 times

4. 근전도 신호 처리 및 분류

측정된 근전도 데이터는 300 Hz로 다운샘플링(downsampling)한 후, 개별 손가락 움직임 시점 기준으로 2초의 데이터만을 잘라 분석에 사용하였다. 신호 측정 시 발생한 오프셋 값을 제거하기 위하여 피험자의 손가락 움직임이 거의 발생하지 않는 0-0.4 초 구간의 근전도 평균값을 각 시간 데이터 값에서 빼주는 기준 보정(baseline correction)을 수행하였다. 7개의 서로 다른 손가락 움직임 분류를 위한 특징으로 근전도 분석에서

주로 사용하는 평균 절대 편차(Mean Absolute Value: MAV), 평균 제곱근 편차(Root Mean Square: RMS)와 함께, 평균(MEAN)을 0.4-0.8초, 0.8-1.2초, 1.2-1.6초, 1.6-2.0초의 시간 윈도우 구간에서 각각 계산하였다. 특징 벡터는 개별 시행별 근전도 데이터로부터 추출한 정량적 값을 가지는 특징 집합을 의미하며, MAV, RMS, MEAN을 각각 이용하여 구성하거나 세 가지 특징을 모두 이용(ALL)하여 구성하였다. 각 피험자별 7개의 서로 다른 손가락 움직임을 40회씩 수

3

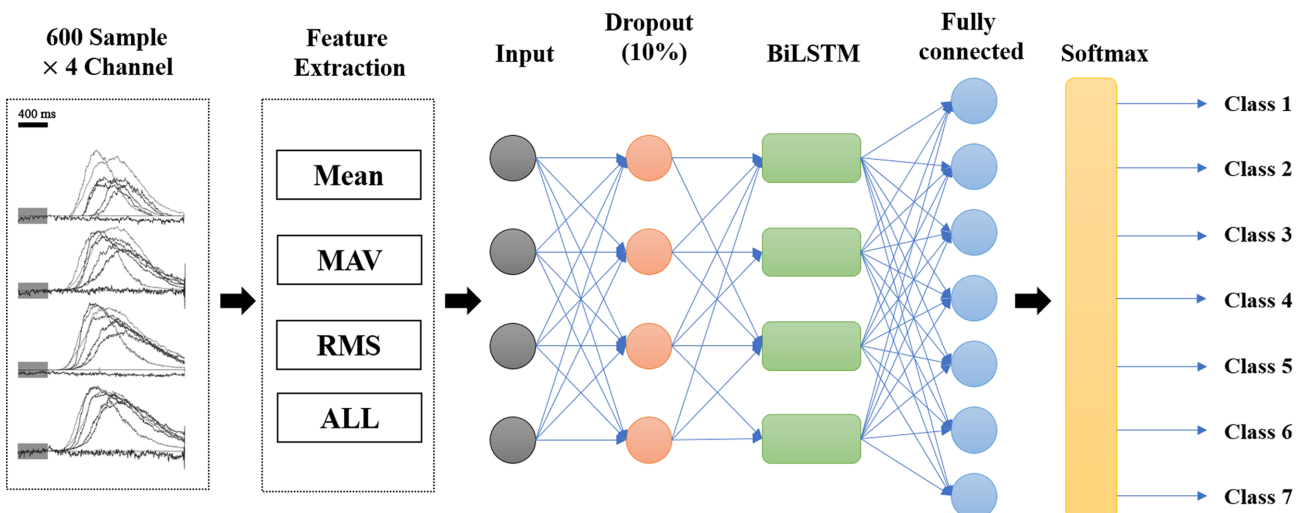


그림 3. 7개의 서로 다른 손가락 움직임을 분류하기 위해 사용한 LSTM 모델의 구조. BiLSTM층의 입력 가중치(input weight), 순환 가중치(recurrent weight), 바이어스(bias) 각각의 크기는 800×4 , 800×100 , 800×1 이며, fully connected층의 가중치(weight)와 바이어스(bias) 크기는 7×200 과 7×1 임

Fig. 3. (a) Structure of the LSTM model used to classify seven different finger movements. The sizes of input weight, recurrent weight, and bias are 800×4 , 800×100 , and 800×1 , respectively, in the BiLSTM layer, and those of weight and bias are 7×200 and 7×1 , respectively, in the fully connected layer

행하였으므로, 개별 피험자별 280개의 특징 벡터가 존재하게 되며, 이를 분류에 사용하였다.

$$MAV = \frac{1}{N} \sum_{k=1}^N |x[k]| \quad (1)$$

$$RMS = \sqrt{\frac{1}{N} \sum_{k=1}^N x^2[k]} \quad (2)$$

$$MEAN = \frac{1}{N} \sum_{k=1}^N x[k] \quad (3)$$

서로 다른 손가락 움직임 분류를 위해 순환 신경망(Recurrent Neural Networks: RNN)의 일종인 Long Short-Term Memory(LSTM)를 이용하였다. 그림 3은 본 연구에서 사용한 LSTM을 이용한 심층 신경망(Deep Neural Network) 모델을 나타낸다. 4개의 채널에서 근전도 데이터로부터 추출한 특징을 입력 받아 과적합을 방지하기 위하여 10%의 dropout을 수행하였고, bidirectional LSTM(biLSTM) layer를 이용하여 모델을 학습하였다. 최종적으로 7 종류의 근전도 신호에 대한 분류 결과를 출력하였다. 위의 과정을 앞서 추출한 4가지 서로 다른 특징(MAV, RMS, MEAN, ALL)들에 대해 독립적으로 적용하여 분류 정확도를 산출하였다.


또한, 근전도 분류 연구에서 많이 사용되고 있는 LDA 분류기를 이용하여 분류 정확도를 계산하였으며, 그 정확도를 LSTM 정확도와 비교하여 LSTM의 성능을 객관적으로 비교하였다. 이를 위해, LDA를 활용한 분류를 수행할 때 LSTM과 동일하게 MAV, RMS, MEAN, ALL 특징에 대해 각각 분류 정확도를 계산하였다. MAV, RMS, MEAN 특징을 조합한 ALL 특징은 LSTM에서는 그대로 분류에 사용하였지만, LDA의 경우 Relief 알고리즘을 이용하여 최적의 특징 선택(Feature Selection: FS)을 추가적으로 수행한 후 분류에 사용하였다[12-14]. 이는 LDA의 분류 정확도를 최대화하여 딥러닝(LSTM) 알고리즘의 유용성을 보다 엄격하게 검증하기 위함이었다.

과적합(overfitting) 방지하고 일반화된 분류 정확도를 계산하기 위해 5 × 5-fold 교차 검증을 수행하였다. 교차 검증을 위한 데이터 분할은 그림 4에 설명되어 있다. 각 피험자별 280개의 단일 시행 데이터(7 종류 손가락 움직임 × 40회 시행)를 5개로 분할하였다. LSTM 학습을 위해 3개의 분할 데이터(training data)를 분류기의 하이퍼파라미터(hyperparameter) 선택을 위해, 1개의 분할 데이터(validation data)를 학습한 LSTM 모델의 검증을 위해, 나머지 1개의 분할 데이터(test data)를 학습한 LSTM 모델의 최종 성능 확인을 위해 사용하였다. LDA 분류기를 위한 교차 검증 단계에서는 검증 데이터(validation data)가 필요하지 않기 때문에, LSTM 학습과 형평성을 맞추기 위해 3개의 분할 데이터(training data)를 이용하여 LDA 분류기를 학습하였고 학습한 LDA 분류기의 성능을 1개의 분할 데이터(test data)로 확인하였다. LSTM 분류기 학습에 사용한 검증 데이터(validation data)에 대응하는 분할 데이터는 LDA 학습 및 분류에서 사용하지 않았다. 이러한 교차 검증 과정을 전체 데이터를 서로 다르게 무작위로 분할하여 5번 반복 수행하였다(5 × 5-fold 교차 검증).

5. 통계

LSTM과 LDA 분류기를 이용하여 계산한 분류 정확도의 통계적 유의성을 확인하였다. 정규분포 분위수 대조도(quantile-quantile plot)를 이용한 검사 결과 데이터가 정규성을 만족하지 못했기 때문에, 비모수 검정법인 프리드만 검정(Friedman test)을 이용하였다. 사후 검정(post-hoc test)을 위하여 윌콕슨 부호 순위 검정(Wilcoxon signed rank test)을 이용하여 통계적 유의성(p-value)을 계산하였고, 제 1종 오류를 조절하기 위하여 false discovery rate(FDR) 방법을 이용하여 p-value를 보정하였다.

(a) 5-fold cross-validation for LSTM



(b) 5-fold cross-validation for LDA




그림 4. 5-fold 교차 검증을 위한 (a) LSTM과 (b) LDA에 대한 데이터 분할 과정에 대한 설명. 초록, 파랑, 빨강색 사각형은 각각 학습(train), 검증(valid), 테스트(test)를 위해 분할된 데이터를 나타낸다. LDA의 경우 별도의 검증(valid)과정이 없으므로, 공평한 비교를 위해 LSTM사용한 검증(valid)데이터를 사용하지 않았다

Fig. 4. Explanation of data split related to LSTM and LDA for 5-fold cross-validation. Green, blue, and red squares indicate training, validation, and test data, respectively. Because a validation procedure is not required for LDA, the validation data used for LSTM is not used for LDA for fair comparison

III. 연구 결과

1. 근전도 파형

그림 5는 7가지 서로 다른 손가락 움직임을 수행할 때 발생한 근전도 신호의 전체 피험자 평균값을 나타내고 있다. 과제가 제시되고 피험자가 이를 인식하는 동안은(약 0-0.4 s) 4개의 근전도 측정 채널 모두에서 의미 있는 근전도 신호 변화가 보이지 않지만, 그 후 피험자가 주어진 손가락 움직임을 수행하는 동안 근전도 신호의 큰 변화가 나타나는 것을 확인할 수 있다. 특히, 손가락 움직임 별로 근전도 신호의 진폭과 반응 시점이 채널에 따라 다르게 나타나는데, 이러

한 변화가 근전도 신호를 이용한 서로 다른 손가락 움직임 자동 분류에 중요한 특징으로 활용되었음을 추론할 수 있다.

2. 분류 정확도

그림 6은 MAV, RMS, MEAN, 그리고 3개의 특징을 한번에 사용한 ALL에 대한 LSTM과 LDA 분류 정확도를 나타내고 있다. 앞서 언급한 것처럼 LDA의 경우 3개의 특징을 한번에 사용한 ALL대신 분류에 가장 적합한 특징을 선택(FS)한 후 분류에 사용하였다. LDA의 경우 MAV, RMS, MEAN, FS모두 통계적 차이는 나지 않았지만 평균적으로 FS의 분류 정확도가 가장 높았다($84.9 \pm 5.8\%$). LSTM의 경우, 세 가지




그림 5. 시간에 따른 7 종류 손가락 움직임 별(엄지(Thumb), 검지(Index), 중지(Middle), 약지(Ring), 새끼(Little) 손가락, 주먹 쥐기(Fist), 휴식 상태(Rest)) 전체 피험자의 평균 근전도 신호 변화. 신호 크기는 0-1 범위로 정규화 하였으며($x_{norm}[k] = (x[k] - x_{min}) / (x_{max} - x_{min})$), 시각 음영 부분은 0-0.4초의 기준 보정(baseline correction) 구간을 나타낸다

Fig. 5. EMG changes averaged over all subjects for each finger movement (thumb, index, middle, ring, little, fist, and rest) along the time. EMG values are normalized between 0 and 1 ($x_{norm}[k] = (x[k] - x_{min}) / (x_{max} - x_{min})$), and shaded rectangle areas present a time period of 0-0.4 s used for baseline correction




그림 6. 4가지 특징별(MAV, RMS, MEAN, and FS for LDA or ALL for LSTM) LSTM(청색 계열)과 LDA(적색 계열) 분류기를 이용하여 계산한 분류 정확도. LSTM의 경우 3가지 특징을 동시에 모두 사용하였으나(ALL), LDA의 경우 특징 선택 알고리즘을 이용하여 최적의 특징을 선택 사용한다(FS). 오차 막대는 표준 편차를 나타내며, 통계적 유의성 표시는(** $p < 0.01$ 및 * $p < 0.05$) LSTM (ALL)과 이외의 경우에 대해서만 나타낸다

Fig. 6. Classification accuracies of LSTM and LDA with respect to four different features (MAV, RMS, MEAN, and FS for LDA or ALL for LSTM). A combination of three features (MAV, RMS, and MEAN) is used for LSTM (ALL) while optimal features selected by a feature selection algorithm are used for LDA (FS). Error bars indicate standard deviations of classification accuracies, and statistically significant marks (** $p < 0.01$ and * $p < 0.05$) are presented based on LSTM (ALL)

표 1. 개별 피험자별 특징 및 분류기에 따른 분류 정확도

Table 1. Classification accuracies of each subject with respect to the feature type and classifier

Participant	LDA (%)				LSTM (%)			
	MEAN	MAV	RMS	FS	MEAN	MAV	RMS	ALL
1	75.38	74.64	76.07	82.57	91.86	89.86	90.29	91.86
2	75.57	73.50	74.29	71.93	81.29	81.57	81.29	82.21
3	83.64	83.57	84.93	87.21	93.36	93.79	94.29	93.36
4	87.71	87.79	88.71	86.71	92.64	91.64	91.71	92.14
5	91.00	90.50	89.86	93.86	95.57	96.07	95.57	94.93
6	82.64	81.36	81.71	82.50	95.29	95.29	95.21	95.50
7	89.71	90.14	91.64	89.43	93.71	93.43	93.71	93.71
8	81.07	77.93	79.00	80.71	86.64	83.57	84.43	86.21
9	79.36	79.07	79.29	82.21	90.86	89.36	89.71	91.29
10	82.43	82.50	83.14	82.86	91.36	91.43	92.21	91.43
Mean	82.85	82.10	82.86	84.00	91.26	90.60	90.84	91.26
Std.	5.40	6.02	5.90	5.87	4.33	4.77	4.69	4.09

표 2. 평가특징 중 최고 평균 분류 정확도를 도출한 LDA(FS특징)와 LSTM(ALL특징) 모델을 사용한 개별 피험자별 민감도, 특이도, 분류 정확도
Table 2. Sensitivities, specificities, and adjusted accuracies of each subject for the LDA (FS) and LSTM (ALL) models showing the best mean classification accuracies

Participant	LDA (%)			LSTM (%)		
	Sensitivity	Specificity	Adjusted Accuracy	Sensitivity	Specificity	Adjusted Accuracy
1	83.18	82.59	82.57	92.08	91.86	91.86
2	71.88	71.93	71.93	82.16	82.21	82.21
3	87.19	87.21	87.21	93.37	93.36	93.36
4	86.95	86.72	86.71	92.59	92.16	92.14
5	93.94	93.86	93.86	94.99	94.93	94.93
6	84.54	82.57	82.50	95.57	95.50	95.50
7	89.93	89.44	89.43	94.02	93.72	93.71
8	80.96	80.72	80.71	86.67	86.23	86.21
9	82.90	82.24	82.21	91.32	91.29	91.29
10	84.04	82.89	82.86	91.87	91.44	91.43
Mean	84.55	84.02	84.00	91.46	91.27	91.26
Std.	9.61	6.00	5.87	6.72	4.18	4.09

특징을 모두 이용하여 계산한 분류 정확도(LSTM (ALL))가 가장 높았고($91.2 \pm 4.1\%$), RMS를 이용한 분류 정확도($88.0 \pm 6.8\%$) 대비 통계적으로 유의미한 차이가 있었다(corrected- $p < 0.05$). 또한, 세 가지 특징을 모두 이용하여 계산한 LSTM 분류 정확도는 LDA를 사용하여 획득한 모든 분류 정확도 대비 통계적으로 유의미하게 우수하였다(corrected- $p < 0.01$). 표 1은 개별 피험자별 특징과 분류기에 따른 분류 정확도를 나타내고 있으며, 표 2는 LDA와 LSTM 각각 최대 평균 분류 정확도를 보이는 특징을 사용했을 때의 민감도, 특이도, 분류 정확도를 개별 피험자별로 나타내고 있다.

IV. 고찰 및 결론

본 연구에서는 손가락 기반 전자 의수 개발에 기여하기 위해, 서로 다른 손가락 움직임을 수행할 때 유도된 근전도를 순환 신경망(RNN)의 한 종류인 LSTM을 이용하여 분류를 수행하였다. 서로 다른 3가지 특징(MAV, RMS, MEAN)을 조합한 특징을 분류에 사용할 경우 10명 피험자로부터 평균 $91.2 \pm 4.1\%$ 의 높은 분류 정확도를 얻을 수 있었다. 본 연구에서 제안한 LSTM 모델의 객관적인 성능을 검증하기 위해 선행 연구에서 가장 많이 활용한 LDA를 이용하여 분류 정확도를

산출 및 비교한 결과, LSTM의 성능이 LDA보다 통계적으로 유의미하게 우수함을 확인 할 수 있었다. 하지만, 본 연구에서 획득한 연구 결과를 보다 신중하게 증명하기 위해서는 실시간으로 근전도 신호를 측정하면서 분류 정확도를 산출하는 온라인 실험의 수행이 추가적으로 필요하다.

본 연구에서 사용한 순환 신경망 외에도 심층 신경망(Deep Neural Network), 합성곱 신경망(Convolutional Neural Network), 제한 볼츠만 머신(Restricted Boltzmann Machine), 심층 신뢰 신경망 (Deep Belief Network), 심층 Q-네트워크(Deep Q-Network)등의 다양한 딥러닝 알고리즘이 제안되고, 생체 신호 처리에 활용이 되고 있다. 본 연구에서는 생체 신호 처리 연구에 많이 사용 되어온 순환 신경망 중 하나인 LSTM을 사용하였지만[15-17], 딥러닝 모델의 성능은 적용 데이터에 크게 의존적이므로 타 딥러닝 모델 적용을 통한 손가락 움직임 분류 성능 향상의 여지가 남아 있다. 추후 추가 연구를 통해 근전도 신호 분석에 가장 잘 작동하는 딥러닝 모델을 탐색하는 연구를 수행하고자 한다.

일부 선행 연구에서 새로운 피험자로부터 분류기 학습에 필요한 근전도 데이터를 측정하지 않고 다른 피험자의 근전도 데이터로 기구축한 분류기를 새로운 피험자에게 그대로 적용하는 연구가 시도 되었다[18,19]. 해당 방법은 새로운 피험자로부터 분류기 학습에 필요한 근전도 데이터를 수집하지 않아도 되기 때문에, 본 연구에서처럼 개별 피험자로부터 분류 모델 구축을 위해 학습 데이터를 수집하는 방법보다 실용성 측면에서 우수하다. 하지만, 개별 피험자별 근전도 신호의 특성이 크게 상이하기 때문에, 앞서 언급한 방법은 개별 피험자별로 학습 데이터를 이용한 분류 방법보다 정확도 측면에서 성능이 크게 떨어지는 것으로 확인 되었다 [18,19]. 다른 선행 연구에서는 다른 피험자로부터 기구축한 분류 모델에 새로운 피험자의 소수 학습 데이터만을 새롭게 적용하여 기존 모델을 새로운 피험자에게 적합하도록 조정하는 적응형(adaptation) 학습 방법이 제안되기도 하였다[20-22]. 앞서 소개한 피험자 독립적인 학습 모델과 적응형 학습을 사용하는 방법 모두 학습 데이터 수집 시간을 줄 일 수 있다는 측면에서 궁극적으로 근전도 기반 분류 연구가 나아가야 할 방향으로 사료된다. 본 연구에서 기존 LDA 방법보다 우수한 성능을 보인 LSTM을 활용하여 피험자 독립적인 학습과 적응형 학습 모델을 개발하는 것은 좋은 후속 연구 주제가 될 수 있으리라 사료된다.

참고문헌

- [1] Michielli N, Acharya UR, Molinari F. Cascaded LSTM recurrent neural network for automated sleep stage classification using single-channel EEG signals. *Comput Biol Med.* 2019;106:71-81.
- [2] Alhagry S, Fahmy AA, El-Khoribi RA. Emotion recognition based on EEG using LSTM recurrent neural network. *Emotion.* 2017;8:355-8.
- [3] Davidson PR, Jones RD, Peiris MT. EEG-based lapse detection with high temporal resolution. *IEEE Trans Biomed Eng.* 2007;54:832-9.
- [4] Hwang HJ, Hahne JM, and Müller KR. Channel selection for simultaneous and proportional myoelectric prosthesis control of multiple degrees-of-freedom. *J Neural Eng.* 2014;11:056008.
- [5] Hahne JM, Dähne S, Hwang HJ, Müller KR, Parra LC. Concurrent adaptation of human and machine improves simultaneous and proportional myoelectric control. *IEEE Trans Neural Syst Rehabil Eng.* 2015;23:618-27.
- [6] Vidovic MM, Hwang HJ, Amsüss S, Hahne JM, Farina D, Müller KR. Improving the robustness of myoelectric pattern recognition for upper limb prostheses by covariate shift adaptation. *IEEE Trans Neural Syst Rehabil Eng.* 2016;24:961-70.
- [7] Adewuyi AA, Hargrove LJ, Kuiken TA. An analysis of intrinsic and extrinsic hand muscle EMG for improved pattern recognition control. *IEEE Trans Neural Syst Rehabil Eng.* 2016;24; 485-94.
- [8] Englehart K, Hudgins B. A robust, real-time control scheme for multifunction myoelectric control. *IEEE Trans Biomed Eng.* 2003;50:848-54.
- [9] Huang Y, Englehart KB, Hudgins B, Chan AD. A Gaussian mixture model based classification scheme for myoelectric control of powered upper limb prostheses. *IEEE Trans Biomed Eng.* 2005;52:1801-11.
- [10] Chan AD, Englehart KB. Continuous myoelectric control for powered prostheses using hidden Markov models. *IEEE Trans Biomed Eng.* 2004;52:121-4.
- [11] Ajiboye AB and Weir RF. A heuristic fuzzy logic approach to EMG pattern recognition for multifunctional prosthesis control. *IEEE Trans Neural Syst Rehabil Eng.* 2005;13:280-91.
- [12] Sebelius FC, Rosen BN, Lundborg GN. Refined myoelectric control in below-elbow amputees using artificial neural networks and a data glove. *J Hand Surg.* 2005;30:780-9.
- [13] Li G, Schultz AE, Kuiken TA. Quantifying pattern recognition—based myoelectric control of multifunctional transradial prostheses. *IEEE Trans Neural Syst Rehabil Eng.* 2010;18:185-92.
- [14] Hahne JM, Graimann B, Müller KR, “Spatial filtering for robust myoelectric control,” *IEEE Transactions on Biomedical Engineering,* 2019;59:1436-43.
- [15] Kira K, Rendell LA. The feature selection problem: traditional methods and a new algorithm. *Proceedings of the Tenth National Conference on Artificial Intelligence.* 1992:129-34.
- [16] Kira K, Rendell LA. A practical approach to feature selection. in *Machine Learning Proceedings 1992 ed.* Elsevier; 1992, pp. 249-256.
- [17] Kononenko I, Šimec E, Robnik-Šikonja M. Overcoming the myopia of inductive learning algorithms with Relief. *Appl Intell.* 1997;7:39-55.
- [18] Castellini C, Fiorlla AE, Sandini G. Multi-subject/daily-life activity EMG-based control of mechanical hands. *J Neuro-Eng Rehabil.* 2009;article number: 41.
- [19] Gibson AE, Ison MR, Artemiadis P. User-independent hand motion classification with electromyography. 2013 *Dynamic Systems and Control Conference.* 2013.
- [20] Matsubara T, Morimoto J. Bilinear modeling of emg signals

- to extract user-independent features for multiuser myoelectric interface. IEEE Trans Biomed Eng. 2013;60:2205-13.
- [21] Park KH, Lee SW. Movement intention decoding based on deep learning for multiuser myoelectric interfaces. 2016 4th International Winter Conference on Brain-Computer Interface. 2016;22-4.
- [22] Khushaba. correlation analysis of electromyogram signals for multiuser myoelectric interfaces. IEEE Trans Neural Syst Rehabil. 2014;22:745-55.